

# **Identificação de desmatamento na Amazônia em imagens de satélite**

Cassiano Zago (DEPEN)

Pedro J. Fernandes (UFF)

Washington R. Dias (Prefeitura de Vitória – ES)


[https://github.com/pjfernandes/amazon\\_deforestation\\_bootcamp\\_enap](https://github.com/pjfernandes/amazon_deforestation_bootcamp_enap)

# Introdução

## Desmatamento na Amazônia

Mais de 20% da floresta foi desmatada durante os últimos 30 anos (KHANNA et al., 2017)

KHANNA, Jaya et al. Regional dry-season climate changes due to three decades of Amazonian deforestation. Nature Climate Change, v. 7, n. 3, p. 200-204, 2017.



<http://terrabrasilis.dpi.inpe.br/>

# Introdução

Impactos ambientais causados pelo desmatamento



Erosão

<http://www.agencia.cnptia.embrapa.br/>



Redução da qualidade da água

<http://www.guladigital.info/>




Alterações no clima local e regional

<https://redesustentabilidade.org.br>

# Introdução (contexto)



Monitoramento do desmatamento por imagens de Sensoriamento Remoto



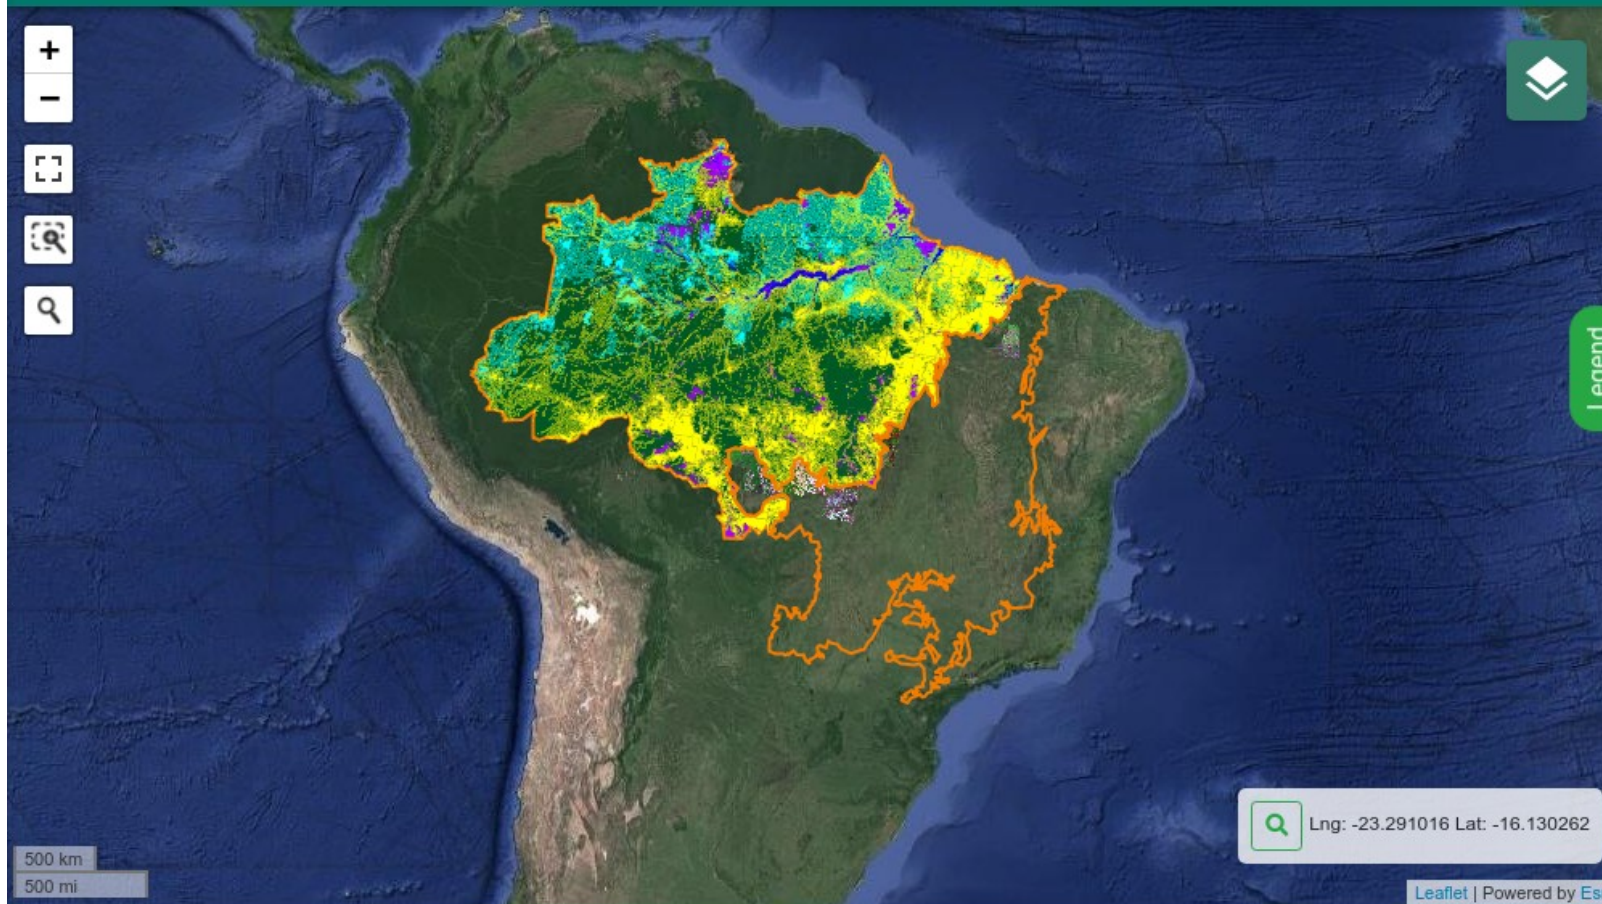
<http://www.seer.ufu.br/index.php/braziliangeojournal/article/view/24886>

# Problema

O PRODES é um projeto desenvolvido pelo INPE e mapeia os polígonos de desmatamento por fotointerpretação das imagens de satélite por especialistas, e fornece as taxas de desmatamento uma vez por ano (INPE, 2019)







# Solução

Para agilizar a quantificação do desmatamento na Amazônia, pode-se utilizar o conhecimento dos especialistas do PRODES para treinar algoritmos de Machine Learning.



# Objetivos

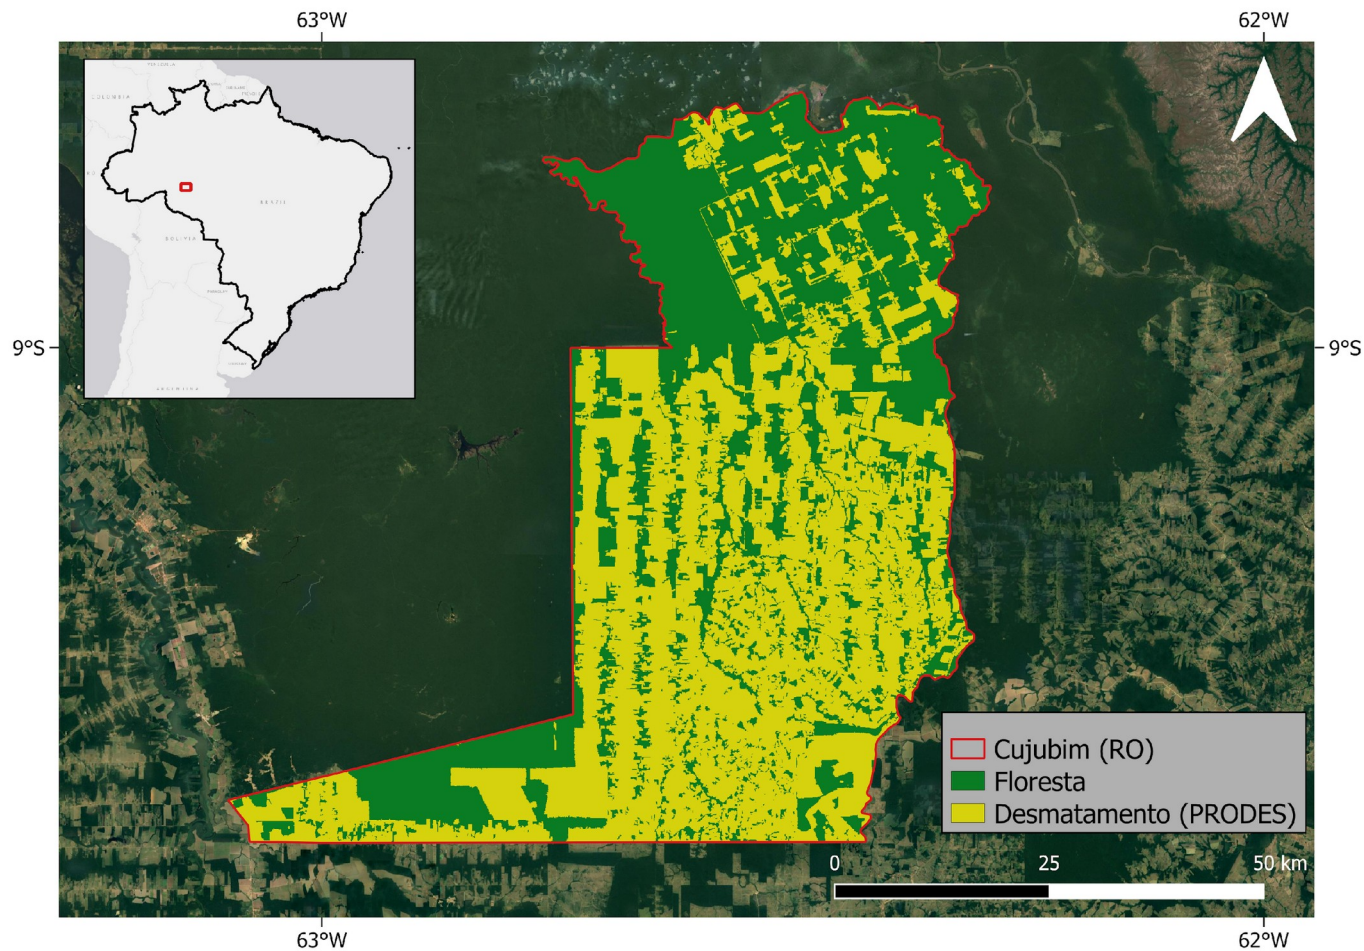
1) Classificar desmatamento em séries temporais (2015-2021) de imagens de satélite (Landsat 8/OLI) a partir de um algoritmo de Machine Learning treinado com amostras do PRODES.

2) Avaliar e comparar o desempenho de diferentes algoritmos.

RandomForestClassifier, LogisticRegression, XGBClassifier, KNeighborsClassifier, BaggingClassifier,  
ExtraTreesClassifier, SVC, NuSVC, LinearSVC, BernoulliNB, LGBMClassifier, MLPClassifier,  
AdaBoostClassifier



# Área de estudo




# Processamento de Imagens (Google Earth Engine)


Diagram illustrating the Google Earth Engine interface and its components:

- search for data
- API documentation
- script manager
- asset manager
- geometry tools
- zoom
- run script
- save script
- get link to script
- imports
- console output
- task manager
- help button
- inspect locations, pixel values, and objects added to the map
- layer manager

The screenshot shows the Google Earth Engine web application. The top navigation bar includes 'Script Editor', 'Assets', 'Layers', 'Tasks', 'Help', and 'Search'. The left sidebar contains a 'Script Manager' with a list of scripts and an 'Assets' panel showing a tree view of data assets. The main area is the 'Script Editor' with a code editor and a 'Run' button. The right sidebar features a 'Console' showing output, a 'Tasks' panel, and a 'Layers' panel. The bottom of the interface is a map of the world with a zoom slider and a layer manager.




<https://landsat.gsfc.nasa.gov/satellites/landsat-8/>



<https://gisenglish.geojamal.com/2019/10/band-combinations-for-landsat-8.html>



$$\text{NDVI} = \frac{(\text{NIR} - \text{Red})}{(\text{NIR} + \text{Red})}$$



<https://www.revistacanafeitos.com.br/o-que-sao-mapas-ndvi-e-como-utiliza-los-na-fazenda>






NDVI (Normalized  
Difference Vegetation  
Index) MODIS  
24/05/2016

# Extração de atributos a partir dos valores dos *pixels* (em linguagem R)



NDVI (2015-2021)

Segmentação



Valores dos pixels extraídos por segmento


SHAPE: (106346, 85)

	masked	mean	classe_amostra	fid	MEDIA_NDVI_2015	MEDIA_NDVI_2016	MEDIA_NDVI_2017	MEDIA_NDVI_2018	MEDIA_NDVI_2019	MEDIA_NDVI_2020
0	-1078580800	-1078580800	0.0	1	0.860178	0.862347	0.880624	0.876968	0.874338	0.866653
1	-1127396665	-1127396665	NaN	2	0.826198	0.861789	0.858303	0.876121	0.843605	0.857290
2	231191332	231191332	0.0	3	0.835334	0.842979	0.841535	0.840028	0.818171	0.834221
3	-1127396665	-1127396665	NaN	4	0.840929	0.840058	0.832866	0.846502	0.839763	0.830259
4	231191332	231191332	0.0	5	0.836446	0.852750	0.864893	0.860996	0.865849	0.846589

5 rows x 85 columns


Cada linha da tabela corresponde a um segmento

Amostras de treinamento: linhas na tabela que possuem rótulo de classe  
0 = Floresta e 1 = Desmatamento




# Resultados (teste de balanceamento de classes com Random Forest)

Train-test split de 30%



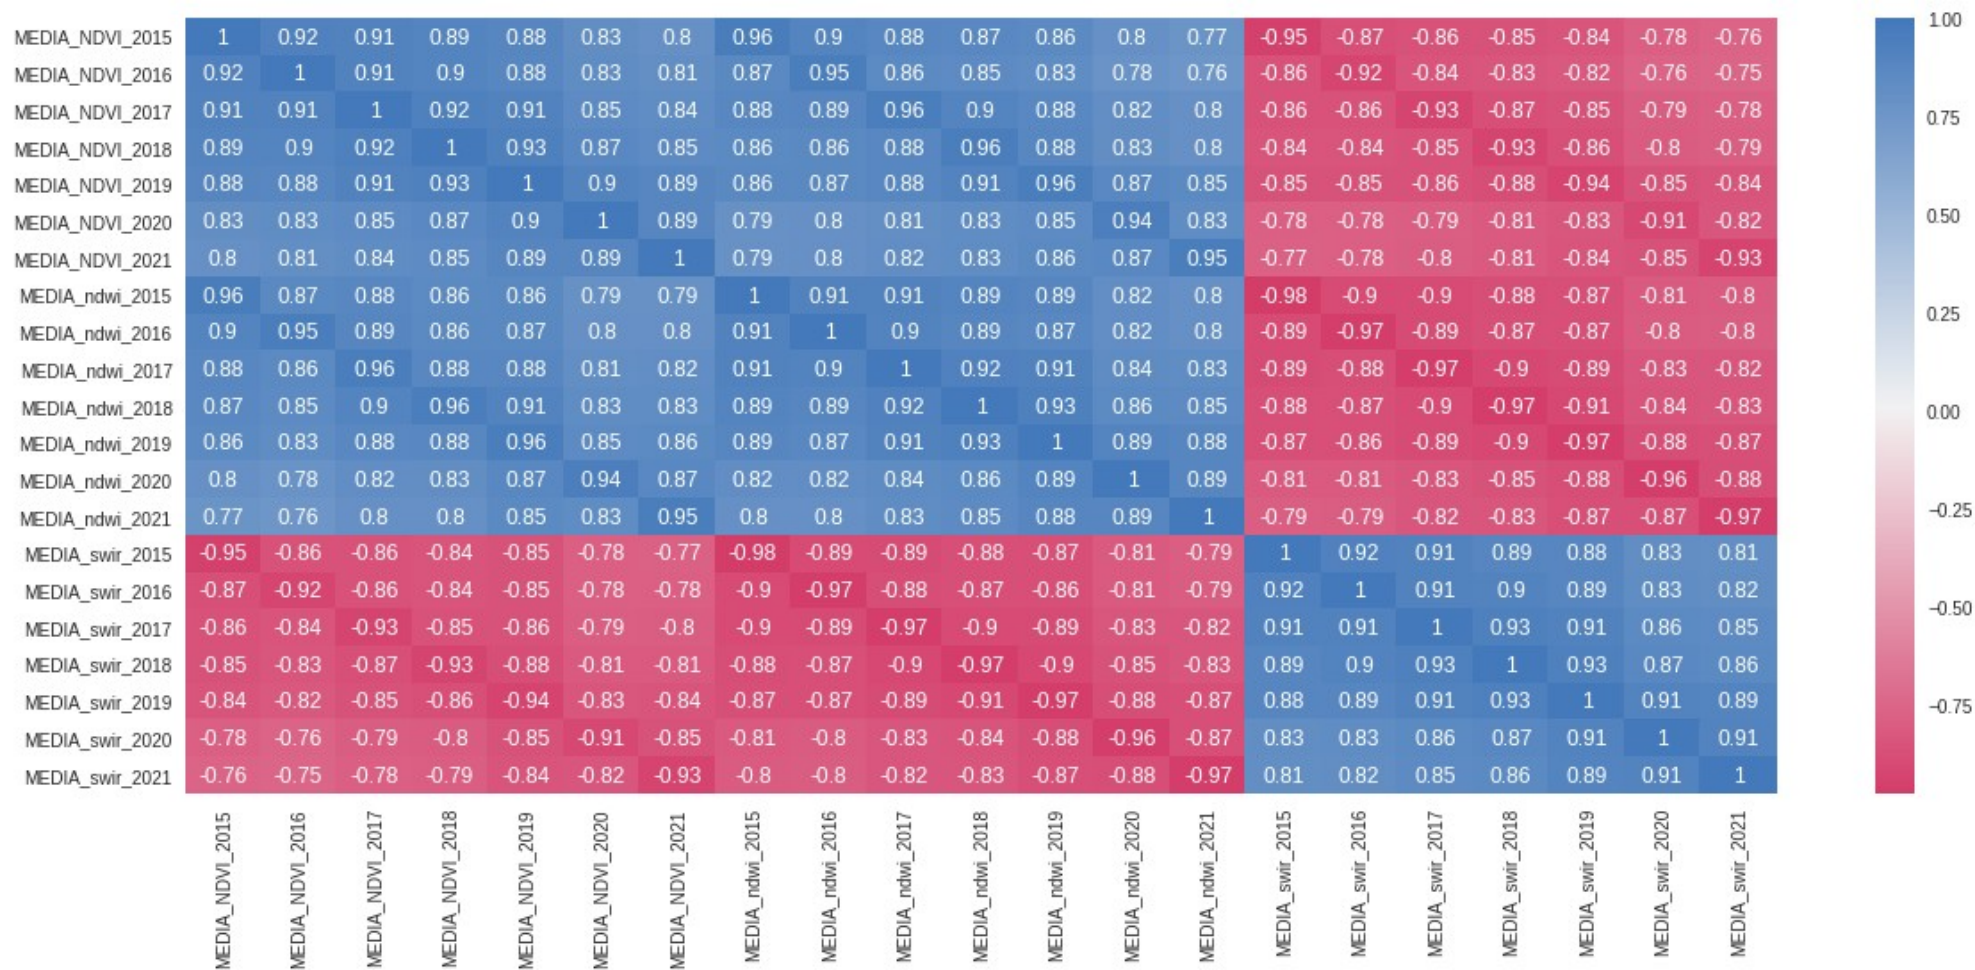
Score: 0.925  
F1-score: 0.919



Score: 0.918  
F1-score: 0.918




# Resultados (testes de seleção de atributos com Random Forest)





Feature Importances of 42 Features using RandomForestClassifier



# Resultados (testes de seleção de atributos com Random Forest)

Train-test split de 30%


Entrada	Score	F1-Score
Todos os atributos (média e mediana de NDVI, NDWI e SWIR)	0.9245	0.919
Atributos de média e mediana de NDVI e NDWI	0.916	0.909
Atributos de média e mediana de SWIR	0.921	0.915
Atributos com contribuição > 0.001	0.9246	0.919

Decidimos utilizar todos os atributos  
42 no total

# Resultados (Escolha do modelo)

Busca de Hiperparâmetros com HalvingGridSearchCV com métrica roc\_auc

RepeatedStratifiedKFold: 10 folds



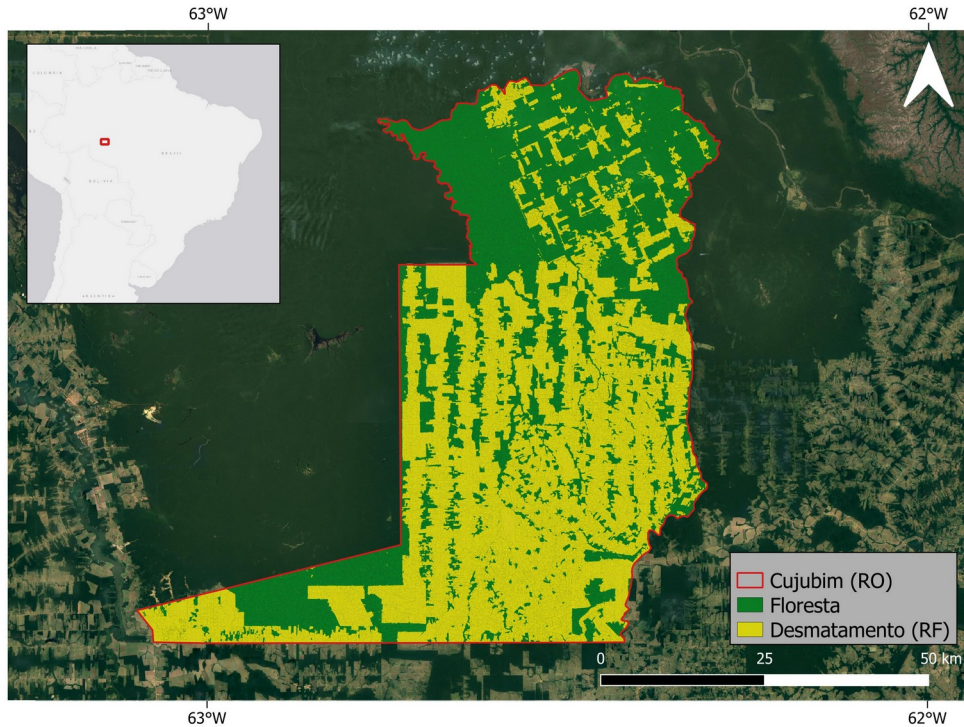
# Resultados (BayesSearchCV e Random Forest)



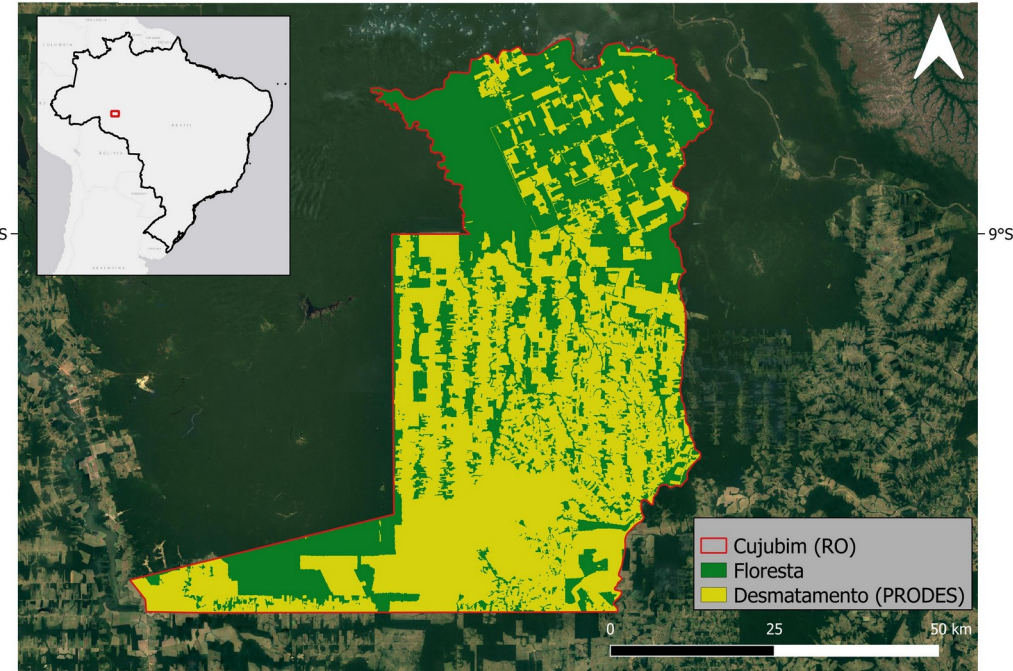
Melhor estimador	Best score (roc auc)
max_depth = 26 max_samples = 1.0 min_samples_leaf = 3 n_estimators= 595	~0.97

# Modelo em produção

A) Classificação Random Forest



B) Mapa PRODES (referência)





# Considerações finais

1) Modelo escolhido foi o Random Forest pelo bom desempenho e pelo uso com bons resultados na literatura de Sensoriamento Remoto.

2) O objetivo não é substituir o PRODES, e sim fornecer valores de área de desmatamento enquanto os valores anuais do PRODES não são divulgados.




3) Além do notebook com os testes de machine learning, outras contribuições foram:

O desenvolvimento de códigos para processamento de imagens e segmentação no Google Earth Engine

Extração de atributos das imagens na linguagem R, contribuindo com o uso de OBIA (Object Based Image Analysis) sem depender de softwares pagos

 **pjfernandes / amazon\_deforestation\_bootcamp\_enap** Public

[Code](#) [Issues](#) [Pull requests](#) [Actions](#) [Projects](#) [Wiki](#) [Security](#) [Insights](#) [Settings](#)

 master  1 branch  0 tags


[Go to file](#)






[Add file](#)

[Code](#)



**pjfernandes** done

1ea8388 1 minute ago  3 commits

 EXTRACT_IMAGES_ATTRIBUTES...	done	1 minute ago
 GENERATE_TRAINING_SET_FRO...	done	1 minute ago
 GOOGLE_EARTH_ENGINE_SCRI...	done	1 minute ago
 apresentacao_ml.pdf	done	5 minutes ago
 notebook_final.ipynb	done	1 hour ago

Help people interested in this repository understand your project by adding a README.

[Add a README](#)

# Planos futuros

- 1) Testar o modelo em áreas em que não houve coleta de amostras.
- 2) Publicar artigo científico.
- 3) Aprofundamento em Deep Learning e em visão computacional.

# **Identificação de desmatamento na Amazônia em imagens de satélite**

Cassiano Zago (DEPEN)

Pedro J. Fernandes (UFF)

Washington R. Dias (Prefeitura de Vitória – ES)

[https://github.com/pjfernandes/amazon\\_deforestation\\_bootcamp\\_enap](https://github.com/pjfernandes/amazon_deforestation_bootcamp_enap)